MCPLE · Evaluación 01 (P1)

Curso de Métodos Computacionales para la Estadística · Doctorado en Ciencia de Datos, Universidad Bernardo O'Higgins · Dr. Eliecer Peña Ancavil (peliecer@docente.ubo.cl)

La P1 es un análisis exploratorio (EDA) individual de un archivo de reseñas de *Age of Empires II: Definitive Edition* que viene sucio a propósito. Se entrega el 30 oct 2026 hasta las 23:47 por el Aula Virtual y vale el 15 % de la nota del curso (Proyecto 1, Unidad 1).

El problema de Genovencio

Genovencio quiere escribir una columna para el diario mural del doctorado con una pregunta simple: ¿a los que más juegan *Age of Empires II* les gusta más el juego? Le pidió a su sobrino que juntara las reseñas de Steam, y el sobrino lo hizo como pudo: unió tres planillas, una por idioma, copió y pegó filas y escribió algunas a mano. Genovencio abrió el archivo y en cinco minutos tenía dos titulares: solo el 90,0 % recomienda el juego, y sus jugadores promedian 782 horas, más de un mes completo frente a la pantalla.

Antes de publicar, alguien le preguntó: «¿Y revisaste los datos?». No los había revisado. Tu trabajo es revisarlos, limpiarlos y decirle a Genovencio qué puede publicar y qué no.

Los datos

El archivo aoe2_resenas_p1.csv tiene 3.938 filas y 9 columnas. Contiene las mismas reseñas reales de Steam que vimos en la Clase 3, recortadas a 9 columnas y con un identificador nuevo. Además de los problemas que los datos reales ya traían, se agregaron otros a propósito, y encontrarlos es parte del trabajo. Trabaja solo con este archivo, no con el de la Clase 3.

Dos datos de contexto te van a servir: el juego salió el 14 de noviembre de 2019 y las reseñas se descargaron el 11 de octubre de 2026.

Columna	Qué es	Tipo esperado
id_resena	Identificador de la reseña. Cada reseña debería aparecer una sola vez.	entero
idioma	espanol (España), latam (español latinoamericano) o ingles	categoría
recomienda	Sí o No: si el autor recomienda el juego	categoría
perfil	Perfil del jugador según sus horas totales, como en la Clase 3: novato (menos de 10 h), intermedio (10 a 100 h), veterano (100 a 1 000 h) o leyenda (1 000 h o más)	categoría con orden
horas_totales	Horas jugadas en total, hasta el día de la descarga	decimal
horas_2_semanas	Horas jugadas en las dos semanas previas a la descarga	decimal
porcentaje_reciente	Porcentaje de las horas totales que se jugó en esas dos semanas: 100 × horas_2_semanas / horas_totales	decimal
resenas_autor	Reseñas que el autor ha escrito en Steam, incluida esta	entero
votos_utiles	Votos de otros usuarios que marcaron la reseña como útil	entero

La columna «Tipo esperado» dice lo que cada columna debería ser. Lo que diga info() puede ser distinto, y esa diferencia también hay que revisarla.

Qué tienes que hacer

Arma un notebook que vaya de los datos crudos a un archivo limpio, con cada decisión escrita. Puedes usar todo lo que vimos entre la Clase 2 y la Clase 4. El orden es una guía: si un paso necesita otro antes, hazlo y explícalo.

1. Cargar y mirar. Carga el CSV en un DataFrame y guarda una copia intacta, original, para compararla al final. Muestra e interpreta head(), info() y describe(), y anota todo lo que te parezca sospechoso.
2. Escribir funciones. Escribe al menos tres funciones y úsalas todas en el análisis. Puedes reutilizar las de la Clase 4 (resumen_nulos, limites_iqr, contar_outliers, imputar, graficar_correlacion), indicando de dónde vienen, pero al menos una tiene que ser tuya.
3. Hacer el EDA. Para cada problema indica cuántas filas afecta, qué decides y por qué. Revisa:
   - las filas repetidas, tanto las idénticas como las que repiten la misma id_resena;
   - las categorías escritas de distintas formas;
   - los nulos (NaN) y los nulos disfrazados, es decir, valores que parecen datos pero significan «sin información»;
   - los valores imposibles y las columnas guardadas con un tipo que no les corresponde;
   - los inf de porcentaje_reciente, una columna que se calculó con los datos sucios;
   - los outliers, con el criterio IQR y un gráfico: ¿son errores o récords?
4. Imputar o no. Decide qué nulos rellenar y cuáles dejar como están. En al menos una columna numérica, compara la imputación con la media y con la mediana, muestra cuánto cambia el resultado y quédate con una. Es una decisión de criterio, así que tienes que justificarla.
5. Codificar. Codifica idioma con one-hot, y perfil como ordinal (novato < intermedio < veterano < leyenda), con un diccionario escrito por ti.
6. Comparar el antes y el después. Arma una tabla como la del barco de Teseo de la Clase 4, comparando original con tu dataset limpio: filas, columnas, nulos, inf, valores imposibles y algunos promedios o medianas. Di con cuántas filas y cuántas columnas terminas.
7. Calcular la correlación. Haz una matriz de correlación con las columnas numéricas y las codificadas. Comenta las relaciones más fuertes y las más débiles, y explica por qué elegiste Pearson o Spearman.
8. Responderle a Genovencio. Recalcula sus dos titulares con los datos limpios: el porcentaje que recomienda el juego, también por idioma, y las horas típicas de un

jugador. Revisa además si a los que más juegan les gusta más el juego, comparando la recomendación por perfil. Cierra con dos o tres párrafos: qué cambió, qué puede publicar Genovencio y qué implicó limpiar los datos.

9. Guardar. Guarda el dataset limpio en Excel y en CSV, sin el índice y con un nombre distinto al del original: aoe2_trabajado.xlsx y aoe2_trabajado.csv.

Si necesitas algo que no vimos, como pd.to_numeric(..., errors="coerce") o np.isinf, úsalo y explica qué hace.

Entrega y reglas

- Qué subes: un zip P1_Apellido_Nombre.zip con tu notebook, P1_Apellido_Nombre.ipynb, y los dos archivos que generaste, aoe2_trabajado.xlsx y aoe2_trabajado.csv. Se sube al Aula Virtual hasta el martes 27 de octubre a las 23:59.
- Reproducible: el notebook tiene que correr completo y sin errores en una sesión nueva de Colab (*Entorno de ejecución → Reiniciar sesión y ejecutar todo*). Revísalo así antes de entregarlo. Al comienzo, deja una celda que muestre las versiones de Python y de las librerías que usaste.
- Código y texto: cada resultado va con su interpretación. Un número o un gráfico sin explicación no suma.
- Inteligencia artificial: puedes usarla, pero al final del notebook indica cuál usaste y para qué. Lo que se evalúa es tu criterio: cada decisión tiene que estar justificada con los datos y tienes que poder explicarla.
- Individual: puedes conversar con tus compañeros, pero el notebook es tuyo.

Rúbrica

Cada uno de los seis criterios tiene la misma ponderación y se evalúa en una escala de 0 a 3 puntos: Excelente (3 puntos), Logrado (2 puntos), En desarrollo (1 punto) e Insuficiente (0 puntos). Un criterio no presentado recibe 0 puntos. El puntaje máximo es de 18 puntos y la nota final se calcula mediante la fórmula:

$$Nota = 1 + 6 \times (puntaje\ obtenido/18)$$

Criterio	Excelente · 3	Logrado · 2	En desarrollo · 1	Insuficiente · 0
1. Carga, reproducibilidad y guardado	Corre completo y sin errores en una sesión nueva de Colab, muestra las versiones, conserva original y guarda el Excel y el CSV sin índice y con otro nombre.	Corre completo, con un detalle menor: una ruta, las versiones o el índice en un archivo.	Hay que corregir algo para que corra, o falta uno de los dos archivos.	No corre o no guarda resultados.
2. Funciones	Tres o más funciones, todas usadas, y al menos una propia que se usa más de una vez.	Tres funciones usadas, pero la propia se usa una sola vez.	Menos de tres funciones, o alguna que no se usa.	Sin funciones, o funciones copiadas que no se usan.
3. Diagnóstico	Encuentra y cuantifica casi todos los tipos de problema del archivo, en todas las columnas donde aparecen.	Encuentra la mayoría, pero deja algún tipo de problema sin revisar.	Encuentra solo los evidentes, como los NaN y los duplicados idénticos.	Muestra salidas sin identificar problemas.
4. Tratamiento y criterio	Cada decisión es coherente con el diagnóstico y está justificada: imputa solo lo que corresponde, compara la media con la mediana y recalcula porcentaje_reciente con los datos limpios.	Decisiones razonables, con alguna justificación débil o un caso sin tratar.	Trata los problemas sin justificarlos, o imputa todo de la misma forma.	Borra filas o rellena sin criterio.

Criterio	Excelente · 3	Logrado · 2	En desarrollo · 1	Insuficiente · 0
5. Codificación y correlación	One-hot de idioma, 0 y 1 en recomienda y perfil ordinal con diccionario; matriz interpretada y elección de Pearson o Spearman justificada.	Codificación correcta y matriz con una interpretación breve.	Falta una codificación o la matriz no se interpreta.	Sin codificación ni matriz.
6. Antes y después, y conclusión	Tabla de comparación completa; responde los dos titulares de Genovencio y la pregunta del perfil, y discute qué decisiones cambian los resultados.	Tabla y respuesta presentes, con una discusión breve.	Falta la tabla o la respuesta a Genovencio.	Sin comparación ni conclusión.